Entrega Preliminar - Aprendizaje de Máquina Aplicado

Predicción del Valor de Mercado de Jugadores de Fútbol

Docente:

Juan Camilo Londoño Lopera

Por:

Carlos Alberto Mazo Gil

Manuel Villegas Michel

Escuela de ciencias e ingeniería

Universidad EAFIT, sede Medellín

2026-1

Índice

Índice 2
Descripción del Problema 3
Contexto y Motivación 3
Pregunta de Investigación 3
Datos Propuestos 3
Fuente(s) de Datos 3
Accesibilidad y Restricciones 3
Enfoque Metodológico Propuesto 4
Tipo de Aprendizaje y Técnicas Candidatas 4
Métrica(s) de Evaluación Principal 4
Herramientas y Entorno Tecnológico 4
Objetivos del Proyecto 4
Objetivo General 5
Objetivos Específicos 5
Revisión de Literatura Preliminar 5
Trabajos Relacionados 5
Gap Identificado / Contribución Esperada 6

Descripción del Problema

Contexto y Motivación

El mercado de transferencias de fútbol profesional mueve miles de millones de euros anualmente, pero la valoración económica de los jugadores sigue siendo un proceso mayormente subjetivo y propenso a sesgos de negociación, generando frecuentes desajustes entre el precio pagado y el valor real del jugador. Esta problemática afecta directamente la sostenibilidad financiera de los clubes y profundiza las desventajas competitivas de aquellas organizaciones sin acceso a herramientas analíticas avanzadas. Machine Learning es una solución apropiada dado que el dataset de Transfermarkt, con más de 157,000 registros históricos de transferencias, contiene patrones complejos y no lineales que modelos como Random Forest o XGBoost pueden aprender eficientemente, permitiendo construir un sistema de predicción objetivo y reproducible que apoye la toma de decisiones en el mercado de fichajes.

Pregunta de Investigación

¿Es posible predecir el valor de mercado de un jugador de fútbol profesional a partir de sus características de transferencia, historial de clubes y temporada, utilizando modelos de aprendizaje supervisado?

Datos Propuestos

Fuente(s) de Datos

https://www.kaggle.com/datasets/davidcariboo/player-scores?select=transfers.csv

Tamaño Estimado	# Features (X)	Variable Objetivo (y)	Tipo de Tarea
~96,338 filas (registros con target válido, de 157,186 totales)	8 variables (transfer_fee, transfer_season, from_club_id, to_club_id, transfer_date, is_free_transfer, club_origin_encoded, club_destination_encoded)	market_value_in_eur — valor continuo en euros	Regresión

Accesibilidad y Restricciones

El dataset es de acceso completamente libre y está disponible públicamente en Kaggle bajo licencia CC BY-SA 4.0, lo que permite su uso académico y de investigación sin restricciones. Los datos provienen de Transfermarkt, una plataforma de dominio público especializada en estadísticas de fútbol, y no contienen información sensible de carácter personal más allá de

nombres de jugadores y clubes ya públicamente conocidos, por lo que no aplican restricciones de privacidad tipo GDPR para el alcance de este proyecto. No se requiere registro especial para su descarga desde el repositorio oficial en GitHub o desde Kaggle.

Enfoque Metodológico Propuesto

Tipo de Aprendizaje y Técnicas Candidatas

El enfoque es de aprendizaje supervisado, dado que se cuenta con una variable objetivo etiquetada (***market_value_in_eur***) para cada registro. Los algoritmos candidatos son:

1. Regresión Lineal, como modelo base interpretable que establece la cota mínima de desempeño.
2. Decision Tree Regressor, por su capacidad de capturar relaciones no lineales y su alta interpretabilidad, permitiendo visualizar explícitamente las reglas que determinan el valor de mercado de un jugador.
3. Random Forest Regressor, elegido por su robustez frente a outliers y por representar una extensión natural del Decision Tree mediante ensamble de múltiples árboles, lo que reduce el sobreajuste y mejora la generalización sobre datos de transferencias no vistos. La distribución fuertemente sesgada del target justifica aplicar transformación logarítmica previa al entrenamiento en todos los modelos.

Métrica(s) de Evaluación Principal

Las métricas principales de evaluación serán RMSE (Root Mean Squared Error) y R^2 (coeficiente de determinación). El RMSE se aplicará sobre el target transformado en escala logarítmica (log-RMSE), dado que el valor de mercado de los jugadores presenta una distribución extremadamente sesgada a la derecha (rango de €10,000 a €180,000,000), por lo que evaluar el error en escala original penalizaría desproporcionadamente los errores en jugadores de élite ignorando el desempeño sobre la mayoría de registros. El R^2 complementa esta métrica al indicar qué proporción de la varianza del valor de mercado es explicada por el modelo, facilitando la comparación directa entre los tres algoritmos candidatos. Como métrica secundaria se reportará el MAE (Mean Absolute Error) en escala original para ofrecer una interpretación económica intuitiva del error promedio en euros.

Herramientas y Entorno Tecnológico

El proyecto se desarrollará en Python 3.10 o posteriores, garantizando accesibilidad y reproducibilidad para todo el equipo. Las bibliotecas a utilizar son: Pandas y NumPy para manipulación y análisis de datos; Scikit-learn para la implementación de los modelos de Regresión Lineal, Decision Tree y Random Forest, así como para el preprocesamiento, validación cruzada y búsqueda de hiperparámetros; Matplotlib y Seaborn para visualizaciones del EDA y resultados; y SHAP para la interpretabilidad de los modelos y análisis de importancia de features.

Objetivos del Proyecto

Objetivo General

Desarrollar un modelo de aprendizaje supervisado capaz de predecir el valor de mercado (en euros) de jugadores de fútbol profesional, a partir de sus datos históricos de transferencias registrados en Transfermarkt, con el fin de estimar cuantitativamente su valoración económica en el mercado actual.

Objetivos Específicos

1. Construir y entrenar al menos tres modelos de regresión (Regresión Lineal, Random Forest y Decision Tree) para predecir el valor de mercado de jugadores de fútbol, alcanzando un coeficiente de determinación $R^2 \geq 0.75$ sobre el conjunto de prueba correspondiente a la temporada 2024/25.
2. Realizar un análisis exploratorio de datos (EDA) y un proceso de preprocesamiento sobre el dataset de transferencias de Transfermarkt, que incluya tratamiento de valores nulos, transformación logarítmica del target e ingeniería de features temporales y de clubes.
3. Identificar y cuantificar las variables con mayor influencia sobre el valor de mercado del jugador mediante análisis de importancia de features, generando un ranking de al menos 5 features clave y su interpretación en el contexto del mercado de fichajes.

Revisión de Literatura Preliminar

Trabajos Relacionados

[1] O. Müller, A. Simons, y M. Weinmann, "Beyond crowd judgments: Data-driven estimation of market value in association football," *European Journal of Operational Research*, vol. 263, no. 2, pp. 611–624, 2017. DOI: 10.1016/j.ejor.2017.05.005

Este es el trabajo fundacional del campo. Los autores construyeron un modelo de regresión multinivel con datos de 4.217 jugadores de las cinco grandes ligas europeas a lo largo de seis temporadas, cuantificando el impacto de más de 20 indicadores sobre el valor de mercado y validándolo contra 845 tarifas de transferencia reales. Identificaron tres grandes familias de variables determinantes: características del jugador (edad, altura), métricas de rendimiento en campo (goles, asistencias, minutos jugados) y factores de popularidad externa (visitas a Wikipedia, menciones en medios).

[2] I. Behravan y S. M. Razavi, "A novel machine learning method for estimating football players' value in the transfer market," *Soft Computing*, vol. 25, no. 3, pp. 2499–2511, 2021. DOI: 10.1007/s00500-020-05319-3

Los autores propusieron un método en dos fases sobre el dataset FIFA 20: primero agruparon automáticamente a los jugadores en cuatro clústeres según posición mediante APSO-clustering, y luego entrenaron modelos de SVR optimizados con algoritmos metaheurísticos (PSO) para cada grupo. Este enfoque reconoció que el valor de mercado tiene dinámicas distintas según la posición del jugador y que tratar a toda la población como homogénea introduce ruido en el modelo.

[3] M. Franceschi, J.-F. Brocard, F. Follert, y J.-J. Gouguet, "Determinants of football players' valuation: A systematic review," *Journal of Economic Surveys*, vol. 38, no. 3, pp. 577–600, 2024. DOI: 10.1111/joes.12552

Esta revisión analizó 29 artículos empíricos y 111 especificaciones de modelos, clasificando 471 variables en seis categorías conceptuales: tiempo, mercado laboral, popularidad, rendimiento, características del club y características del jugador. Sus hallazgos confirman que goles, asistencias, minutos jugados, apariciones y estatus de selección nacional son las variables con mayor respaldo empírico a lo largo de la literatura, y documentan una relación no lineal entre edad y valor de mercado consistente con una curva en forma de U invertida.

[4] (Autor institucional), "Machine learning-driven market value prediction for European football players," *ScienceDirect*, 2025. DOI: 10.1016/S2772-4158(25)00010-0

Este trabajo reciente comparó cuatro modelos (Regresión Lineal Múltiple, Ridge Regression, SVR y Random Forest Regression) evaluados con MAE, MSE, RMSE y R^2 sobre una partición 80/20. Sus resultados mostraron que Random Forest superó a los demás algoritmos al capturar interacciones no lineales y prevenir el sobreajuste, reforzando la conveniencia de los métodos de ensamble para este tipo de tarea de regresión.

Gap Identificado / Contribución Esperada

La literatura revisada evidencia dos limitaciones principales que motivan la propuesta del presente proyecto. En primer lugar, la mayoría de los trabajos existentes construyen sus modelos a partir de variables de rendimiento en campo (goles, asistencias, minutos jugados, valoraciones FIFA), las cuales requieren fuentes de datos propietarias o bases especializadas como Opta o los videojuegos de EA Sports. El presente proyecto, en cambio, trabaja exclusivamente con variables transaccionales y de historial de transferencias disponibles en abierto en Transfermarkt y Kaggle, lo que constituye un enfoque menos explorado en la literatura.

En segundo lugar, trabajos como el de Müller et al. (2017) y Franceschi et al. (2024) señalan explícitamente que la relación entre las características de los clubes de origen y destino, la temporada de transferencia y el valor de mercado resultante ha sido subestimada como fuente de señal predictiva. El presente proyecto busca cuantificar precisamente esa relación, incorporando features de codificación de clubes y temporada como predictores principales, y evaluando si dicha información transaccional (sin necesidad de estadísticas de rendimiento individual) es suficiente para alcanzar un $R^2 \geq 0.75$. De confirmarse, esto representaría un aporte metodológico concreto: la posibilidad de estimar el valor de mercado de un jugador a partir de su trazabilidad de transferencias, sin depender de datos de rendimiento.